

Data augmentation, example generation e próximos passos

Eduardo, Thiago, Vítor

Plano inicial era usar ViT

O artigo “Tackling the Abstraction and Reasoning Corpus with Vision Transformers: the Importance of 2D Representation, Positions, and Objects” demonstra que ViTs não são bons para o ARC-AGI 1.

- Apesar de serem bons para imagens muito mais complexas, ele falha na identificação do grid e dos limites.

Alternativa correlacionada

“Mini-ARC: Solving Abstraction and Reasoning Puzzles with Small Transformer Models”, de Paul Fletcher Hill

- small transformer model (67M)
- resolveu 41% dos puzzles
- fixa em 12x12 a grid

A lacuna

Apesar de usar TTT, somente faz permutações dos exemplos das tasks, não faz data augmentation.

A ideia é comparar 3 cenários:

1. Sem data-augmentation (baseline)
2. Com data-augmentation
3. Ideia do prof. Frederico: “trapacear” gerando inúmeros exemplos para cada puzzle, somente com a finalidade de saber até que ponto mais exemplos auxiliam no aprendizado

Problemas e próximos passos

No mundo ideal não precisamos treinar o modelo do zero: usaríamos o do artigo como baseline e faríamos somente o TTT.

Problema: não disponibiliza o modelo, repositório contém somente script de treino

Treinando modelo do zero: apesar de ser pequeno, demora pra treinar

Ideia de como contornar:

- Usar mini-arc-v12 (versão reduzida, passa de 1440 tokens para 468)
- Datasets: somente o re-arc (no artigo, além desse usa BARC-Heavy e arc-html)

Consequência: teoricamente o experimento ainda serve para validar os 3 cenários, porém nossa baseline nao vai ser os 41% do artigo


Gerando novos exemplos

task **0b148d64**



Gerando novos exemplos

task 0b148d64



Teste com 20 tasks sem “trapaça”

JSON

14 corretas

3 incorretos

3 indefinidas

"accuracy_percentage": **82.35**,
"total_duration_seconds": **184.93**,
"total_tokens": **62953**

Tasks

00d62c1b	1bfc4729
0a938d79	1c786137
0b148d64	1caeab9d
0ca9ddb6	1cf80156
0d3d703e	1e0a9b12
0dfd9992	1e32b0e9
0e206a2e	1f0c79e5
1a07d186	1f642eb9
1b2d62fb	1f85a75f
1b60fb0c	1f876c06

Teste com 20 tasks com “trapaça”

JSON

0 corretas

0 incorretos

20 indefinidas

"accuracy_percentage": **0.0**,

"total_duration_seconds": **195.82**,

"total_tokens": **76515**

Tasks

00d62c1b	1bfc4729
0a938d79	1c786137
0b148d64	1caeab9d
0ca9ddb6	1cf80156
0d3d703e	1e0a9b12
0dfd9992	1e32b0e9
0e206a2e	1f0c79e5
1a07d186	1f642eb9
1b2d62fb	1f85a75f
1b60fb0c	1f876c06

5. Comparação direta

Dimensão	LLM ARChitect	MIT TTT	BARC
Papel principal da augmentation	Mudar a perspectiva e testar estabilidade	Criar dados supervisionados e gerar previsões variadas	Adaptar a transdução; complementar a indução simbólica
Adaptação dos pesos	Não é o foco principal	LoRA por tarefa, duas épocas	LoRA no test-time, três épocas
Construção de dados	Visões transformadas da tarefa	Leave-one-out + transformações + ordem embaralhada	Leave-one-out + transformações + Re-ARC e ARC-Heavy
Transformações	D8, cores e ordem dos exemplos	Geometria, cores, translação, resolução, concatenação e composição	Rotações, flips, diagonais e cores
Geração	DFS probabilística	Greedy	Program sampling no ramo indutivo e beam search no transdutivo
Seleção	Soma de log-probabilidades, AugScore	Votação hierárquica	Verificação de programas + majority vote; fallback transdutivo
Tipo de consistência	Probabilística entre perspectivas	Frequência entre grupos de transformações	Exata para programas e probabilística para transdução
Principal vantagem	Alto recall e bom filtro de candidatos	Adaptação forte com poucos exemplos	Combina flexibilidade neural e verificação simbólica
Principal custo	Muitas buscas e avaliações de candidatos	Treinamento por tarefa e muitas inferências	Amostragem de milhares de programas mais TTT

Tarefa original

|

+--> identidade --> modelo --> resposta 1

+--> flip horizontal --> modelo --> resposta 2

+--> flip vertical --> modelo --> resposta 3

+--> transposição --> modelo --> resposta 4

|

desfazer transformações

|

votação global

|

resposta final

```
{
  "tasks_folder": "20_training",
  "generated_at_utc": "2026-08-27T21:48:51.176613+00:00",
  "model": "gemini-3.1-flash-lite",
  "summary": {
    "total_tasks_evaluated": 20,
    "baseline_accuracy_percentage": 89.47,
    "augmented_accuracy_percentage": 85.0,
    "accuracy_delta_percentage": -4.47,
    "baseline_average_pixel_accuracy_percentage": 97.09,
    "augmented_average_pixel_accuracy_percentage": 99.28,
    "pixel_accuracy_delta_percentage": 2.19,
    "baseline_shape_match_percentage": 100.0,
    "augmented_shape_match_percentage": 100.0,
    "shape_match_delta_percentage": 0.0,
    "baseline_duration_seconds": 514.77,
    "augmented_duration_seconds": 878.09,
    "baseline_tokens": {
      "prompt_tokens": 51731,
      "candidates_tokens": 8887,
      "total_tokens": 60618
    },
    "augmented_tokens": {
      "prompt_tokens": 228755,
      "candidates_tokens": 38415,
      "total_tokens": 267170
    },

```

```
  },
  "net_tasks_gained": 0,
  "fixed_by_augmentation_count": 2,
  "regressed_by_augmentation_count": 2,
  "both_correct_count": 15,
  "both_incorrect_count": 1,
  "other_count": 0
},
```

```

"fixed_by_augmentation": [
  {
    "task_name": "0dfd9992",
    "source_file": "0dfd9992.json",
    "baseline_status": "unknown",
    "augmented_status": "correct",
    "baseline_pixel_accuracy": 0.0,
    "augmented_pixel_accuracy": 100.0,
    "baseline_shape_match": false,
    "augmented_shape_match": true,
    "augmented_consensus_type": "unanimous",
    "augmented_winner_votes": "3/3",
    "augmented_winner_transforms": [
      "flip_horizontal",
      "flip_vertical",
      "transpose"
    ]
  },
  {
    "task_name": "1f642eb9",
    "source_file": "1f642eb9.json",
    "baseline_status": "incorrect",
    "augmented_status": "correct",
    "baseline_pixel_accuracy": 94.0,
    "augmented_pixel_accuracy": 100.0,
    "baseline_shape_match": true,
    "augmented_shape_match": true,
    "augmented_consensus_type": "tie_broken_by_identity",
    "augmented_winner_votes": "1/4",
    "augmented_winner_transforms": [
      "identity"
    ]
  }
]

```

```

"regressed_by_augmentation": [
  {
    "task_name": "1a07d186",
    "source_file": "1a07d186.json",
    "baseline_status": "correct",
    "augmented_status": "incorrect",
    "baseline_pixel_accuracy": 100.0,
    "augmented_pixel_accuracy": 96.96,
    "baseline_shape_match": true,
    "augmented_shape_match": true,
    "augmented_consensus_type": "tie_broken_by_identity",
    "augmented_winner_votes": "1/4",
    "augmented_winner_transforms": [
      "identity"
    ]
  },
  {
    "task_name": "1caeab9d",
    "source_file": "1caeab9d.json",
    "baseline_status": "correct",
    "augmented_status": "incorrect",
    "baseline_pixel_accuracy": 100.0,
    "augmented_pixel_accuracy": 96.0,
    "baseline_shape_match": true,
    "augmented_shape_match": true,
    "augmented_consensus_type": "tie_broken_by_identity",
    "augmented_winner_votes": "1/4",
    "augmented_winner_transforms": [
      "identity"
    ]
  }
]

```



```
"model": "gemini-3.1-flash-lite",
"summary": {
  "total_tasks_evaluated": 10,
  "baseline_accuracy_percentage": 100.0,
  "augmented_accuracy_percentage": 100.0,
  "accuracy_delta_percentage": 0.0,
  "baseline_average_pixel_accuracy_percentage": 100.0,
  "augmented_average_pixel_accuracy_percentage": 100.0,
  "pixel_accuracy_delta_percentage": 0.0,
  "baseline_shape_match_percentage": 100.0,
  "augmented_shape_match_percentage": 100.0,
  "shape_match_delta_percentage": 0.0,
  "baseline_duration_seconds": 119.72,
  "augmented_duration_seconds": 321.73,
  "baseline_tokens": {
    "prompt_tokens": 32945,
    "candidates_tokens": 5807,
    "total_tokens": 38752
  },
  "augmented_tokens": {
    "prompt_tokens": 131780,
    "candidates_tokens": 21510,
    "total_tokens": 153290
  },
  "net_tasks_gained": 0,
  "fixed_by_augmentation_count": 0,
  "regressed_by_augmentation_count": 0,
  "both_correct_count": 10,
  "both_incorrect_count": 0,
  "other_count": 0
}
```

```
},
"consensus_distribution": {
  "unanimous": 6,
  "plurality": 3,
  "tie_broken_by_identity": 1
}
```