

Data augmentation, example generation e próximos passos

Eduardo, Thiago, Vítor

Plano inicial era usar ViT

O artigo “Tackling the Abstraction and Reasoning Corpus with Vision Transformers: the Importance of 2D Representation, Positions, and Objects” demonstra que ViTs não são bons para o ARC-AGI 1.

- Apesar de serem bons para imagens muito mais complexas, ele falha na identificação do grid e dos limites.

Alternativa correlacionada

“Mini-ARC: Solving Abstraction and Reasoning Puzzles with Small Transformer Models”, de Paul Fletcher Hill

- small transformer model (67M)
- resolveu 41% dos puzzles
- fixa em 12x12 a grid

A lacuna

Apesar de usar TTT, somente faz permutações dos exemplos das tasks, não faz data augmentation.

A ideia é comparar 3 cenários:

1. Sem data-augmentation (baseline)
2. Com data-augmentation
3. Ideia do prof. Frederico: “trapacear” gerando inúmeros exemplos para cada puzzle, somente com a finalidade de saber até que ponto mais exemplos auxiliam no aprendizado

Problemas e próximos passos

No mundo ideal não precisamos treinar o modelo do zero: usaríamos o do artigo como baseline e faríamos somente o TTT.

Problema: não disponibiliza o modelo, repositório contém somente script de treino

Treinando modelo do zero: apesar de ser pequeno, demora pra treinar

Ideia de como contornar:

- Usar mini-arc-v12 (versão reduzida, passa de 1440 tokens para 468)
- Datasets: somente o re-arc (no artigo, além desse usa BARC-Heavy e arc-html)

Consequência: teoricamente o experimento ainda serve para validar os 3 cenários, porém nossa baseline nao vai ser os 41% do artigo


Gerando novos exemplos

task **0b148d64**



Gerando novos exemplos

task 0b148d64



Teste com 20 tasks sem “trapaça”

JSON

14 corretas

3 incorretos

3 indefinidas

"accuracy_percentage": **82.35**,
"total_duration_seconds": **184.93**,
"total_tokens": **62953**

Tasks

00d62c1b	1bfc4729
0a938d79	1c786137
0b148d64	1caeab9d
0ca9ddb6	1cf80156
0d3d703e	1e0a9b12
0dfd9992	1e32b0e9
0e206a2e	1f0c79e5
1a07d186	1f642eb9
1b2d62fb	1f85a75f
1b60fb0c	1f876c06

Teste com 20 tasks com “trapaça”

JSON

0 corretas

0 incorretos

20 indefinidas

"accuracy_percentage": **0.0**,

"total_duration_seconds": **195.82**,

"total_tokens": **76515**

Tasks

00d62c1b	1bfc4729
0a938d79	1c786137
0b148d64	1caeab9d
0ca9ddb6	1cf80156
0d3d703e	1e0a9b12
0dfd9992	1e32b0e9
0e206a2e	1f0c79e5
1a07d186	1f642eb9
1b2d62fb	1f85a75f
1b60fb0c	1f876c06